Rapport rendu : Projet 5 Monitoring Kubernetes avec IA

Projet	Project 5 - G17 | KubeAI « Monitoring Kubernetes clusters with AI »
Groupe	Groupe 17 · 3 étudiants
Étudiants	Yao Anassa N'DRI – Vincent TARRIT – Kevin-Eric BONGA
Git URL	https://github.com/VincentTarritMaster/kubeAI
Vidéo de démonstration	https://www.youtube.com/watch?v=EO6ep91FaQc

Architecture

Flux de collecte et d'analyse entre les deux clusters Kubernetes managés (Exoscale SKS, zone ch-gva-2).

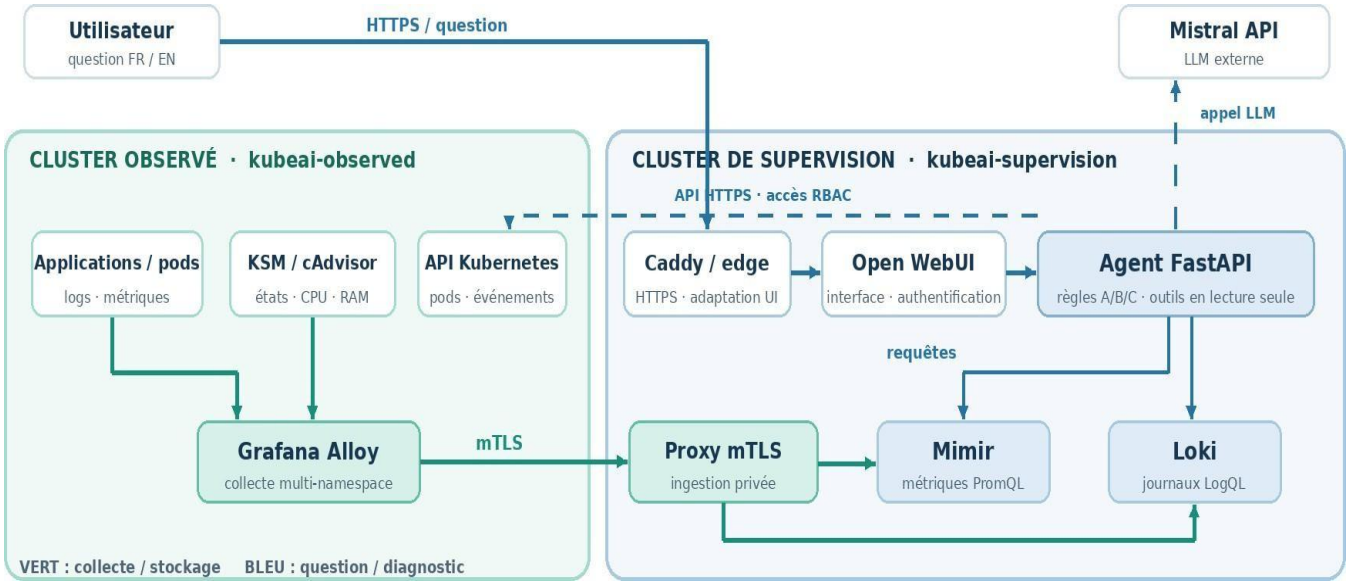


Figure 1 — Collecte : applications et KSM/cAdvisor → Alloy → proxy mTLS → Mimir/Loki. Diagnostic : navigateur → Open WebUI → agent → sources ; Mistral API est externe.

Composants : Rôle et échanges

Composant	Responsabilité et entrées/sorties
Application de démonstration	Émet logs et métriques /metrics , simule un incident HTTP 5xx pour les scénarios B/C.
API Kubernetes	Fournit nœuds, pods et événements à l'agent, accès distant limité en lecture.
KSM + cAdvisor	Expose les états Kubernetes ainsi que les mesures CPU/mémoire des conteneurs.
Grafana Alloy	Collecte logs et métriques des namespaces observés, transmet aux stockages.
Proxy mTLS	Authentifie le collecteur par certificat client et relaie l'ingestion privée.
Grafana Mimir	Conserve les séries de métriques, l'agent les interroge avec PromQL.
Grafana Loki	Conserve les logs horodatés, l'agent les interroge avec LogQL.
Agent FastAPI	Valide les requêtes, lit les sources, rapports A/B/C fondés sur règles et preuves.
LangChain + Mistral API	Outils bornés et modèle externe pour les demandes libres, ne remplace pas les mesures.
Caddy + webui-edge	Assure HTTPS public puis adapte l'affichage des preuves dans Open WebUI.
Open WebUI	Interface de dialogue authentifiée, présente diagnostic, sources et détails dépliables.

Déploiement

Services cloud et modèles réellement utilisés ; les tailles et coûts correspondent à la configuration de démonstration.

Composant	Cloud / modèle	Configuration et mode de déploiement
Clusters Kubernetes	Exoscale SKS Starter · ch-gva-2	2 clusters : kubeai-observed (standard.medium : 2 vCPU/4 GiB) et kubeai-supervision (standard.large : 4 vCPU/8 GiB). 1 nœud/cluster pendant la démo ; 0 hors démo.
Services applicatifs	Conteneurs Kubernetes + Kustomize	Observé : applications, Alloy, kube-state-metrics. Supervision : Mimir, Loki, proxy mTLS, agent, Open WebUI, Caddy, webui-edge.
Stockage	Exoscale SBS · PVC persistants	4 volumes : Alloy 1 Gi, Mimir 10 Gi, Loki 2 Gi, Open WebUI 1 Gi. Conservés lorsque les nœuds sont ramenés à zéro.
Réseau et accès	Réseau privé + Security Groups	Trafic interclusters privé avec mTLS ; seul l'accès WebUI est publié en HTTPS (80/443). Mimir et Loki restent internes.
LLM	Mistral API · mistral-small-2603	Modèle consommé comme service externe ; alternative locale Apertus 8B prévue, non utilisée pour la démo cloud.
Domaine et certificat	Infomaniak DNS + Caddy / Let's Encrypt	https://kubeai.anassndri.ch ; DNS A vers le nœud de supervision, à revérifier après toute recréation de nœud.
Coûts / cycle de vie	Scripts Exoscale start / stop / status	≈ 0,14 CHF/h pour les deux nœuds actifs (estimation hors stockage SBS). 0 nœud à l'arrêt ; volumes toujours facturables.

Tâches

Tâches réalisées	Résultat / livrable	Étudiants impliqués
Choix des technologies cloud	Choix Exoscale SKS ; deux clusters distincts et stockage persistant.	N'DRI, TARRIT, BONGA
Conception de l'architecture	Schéma des flux collecte, ingestion mTLS, interrogation et réponse.	N'DRI, TARRIT, BONGA
Déploiement de l'infrastructure	Clusters SKS, réseau, sécurité, volumes et manifests Kustomize.	N'DRI, TARRIT, BONGA
Chaîne d'observabilité	Alloy, KSM, cAdvisor, Mimir, Loki ; collecte multi-namespace.	N'DRI, TARRIT, BONGA
Développement agent IA	FastAPI, accès Kubernetes/Mimir/Loki, règles A/B/C, outils bornés.	N'DRI, TARRIT, BONGA
Interface et sécurité	Open WebUI FR/EN, HTTPS, authentification, RBAC lecture seule.	N'DRI, TARRIT, BONGA
Tests et démonstrations	441 tests agent + 14 tests scripts ; santé, chronologie, corrélation.	N'DRI, TARRIT, BONGA
Exploitation et coûts	Captures, commandes start/stop/status, estimation ≈ 0,14 CHF/h.	N'DRI, TARRIT, BONGA

Résultats et validation :

KubeAI a été évalué sur l'infrastructure Exoscale à travers trois scénarios représentatifs :

- **(A) Santé globale du cluster :** Détection d'un état **DEGRADED**, malgré un nœud opérationnel (*Ready*), grâce à l'identification de deux pods en attente (*Pending*) parmi 14. Ce résultat démontre une analyse de santé tenant compte de l'ensemble des ressources surveillées.
- **(B) Investigation d'incident :** Reconstitution d'un incident contrôlé à partir des journaux Loki et des métriques Mimir, depuis l'apparition de l'anomalie à **09:10:23 UTC** jusqu'au rétablissement à **09:11:53 UTC**, attestant de la cohérence temporelle des observations.
- **(C) Corrélation et diagnostic :** Mise en relation des erreurs de connexion avec les pics de consommation CPU (**0,1001 cœur**), de latence HTTP p95 (**0,4591 s**) et d'erreurs HTTP 5xx (**100 %**). Les hypothèses sont hiérarchisées selon les éléments observés, sans confondre corrélation et causalité.

Validation technique :

441 tests automatisés réussis, démonstrations sur Exoscale et prise en charge du français et de l'anglais.
Les réponses s'appuient sur des données vérifiables, accessibles dans les preuves techniques.

Sécurité :

L'agent dispose de droits de lecture Kubernetes, empêchant toute modification des ressources lors des diagnostics.